13/11/2023
Version 2

MICROSERVICES

JÉRÉMY PERROUAULT

DISJONCTEUR

SERVICE RÉSILIENT

DISJONCTEUR

- « Service A » a besoin de « Service B » pour composer une réponse
- « Service B » met plus de temps qu'habituellement pour répondre
  - Doit-on continuer à consommer ce service ? Sachant que son délai de réponse alonge celui de « A »
  - Doit-on temporiser sa consommation ? Et mettre en place un mécanisme de contournement ?

- Si « Service B » répond en 250ms au lieu de 10ms habituellement
  - Si on continue de l'appeler, le service risque de saturer encore plus …
  - … Il vaut donc mieux ne pas surcharger les appels, et le laisser reprendre ses capacités
  - Et de répondre avec un traitement alternatif en attendant

- Il nous faut des services résilients

DISJONCTEUR

- Reprendre le scénario précédent, avec plus de services …
  - Le service en erreur, finira par mettre en erreur toute la chaine d'appel (effet domino)

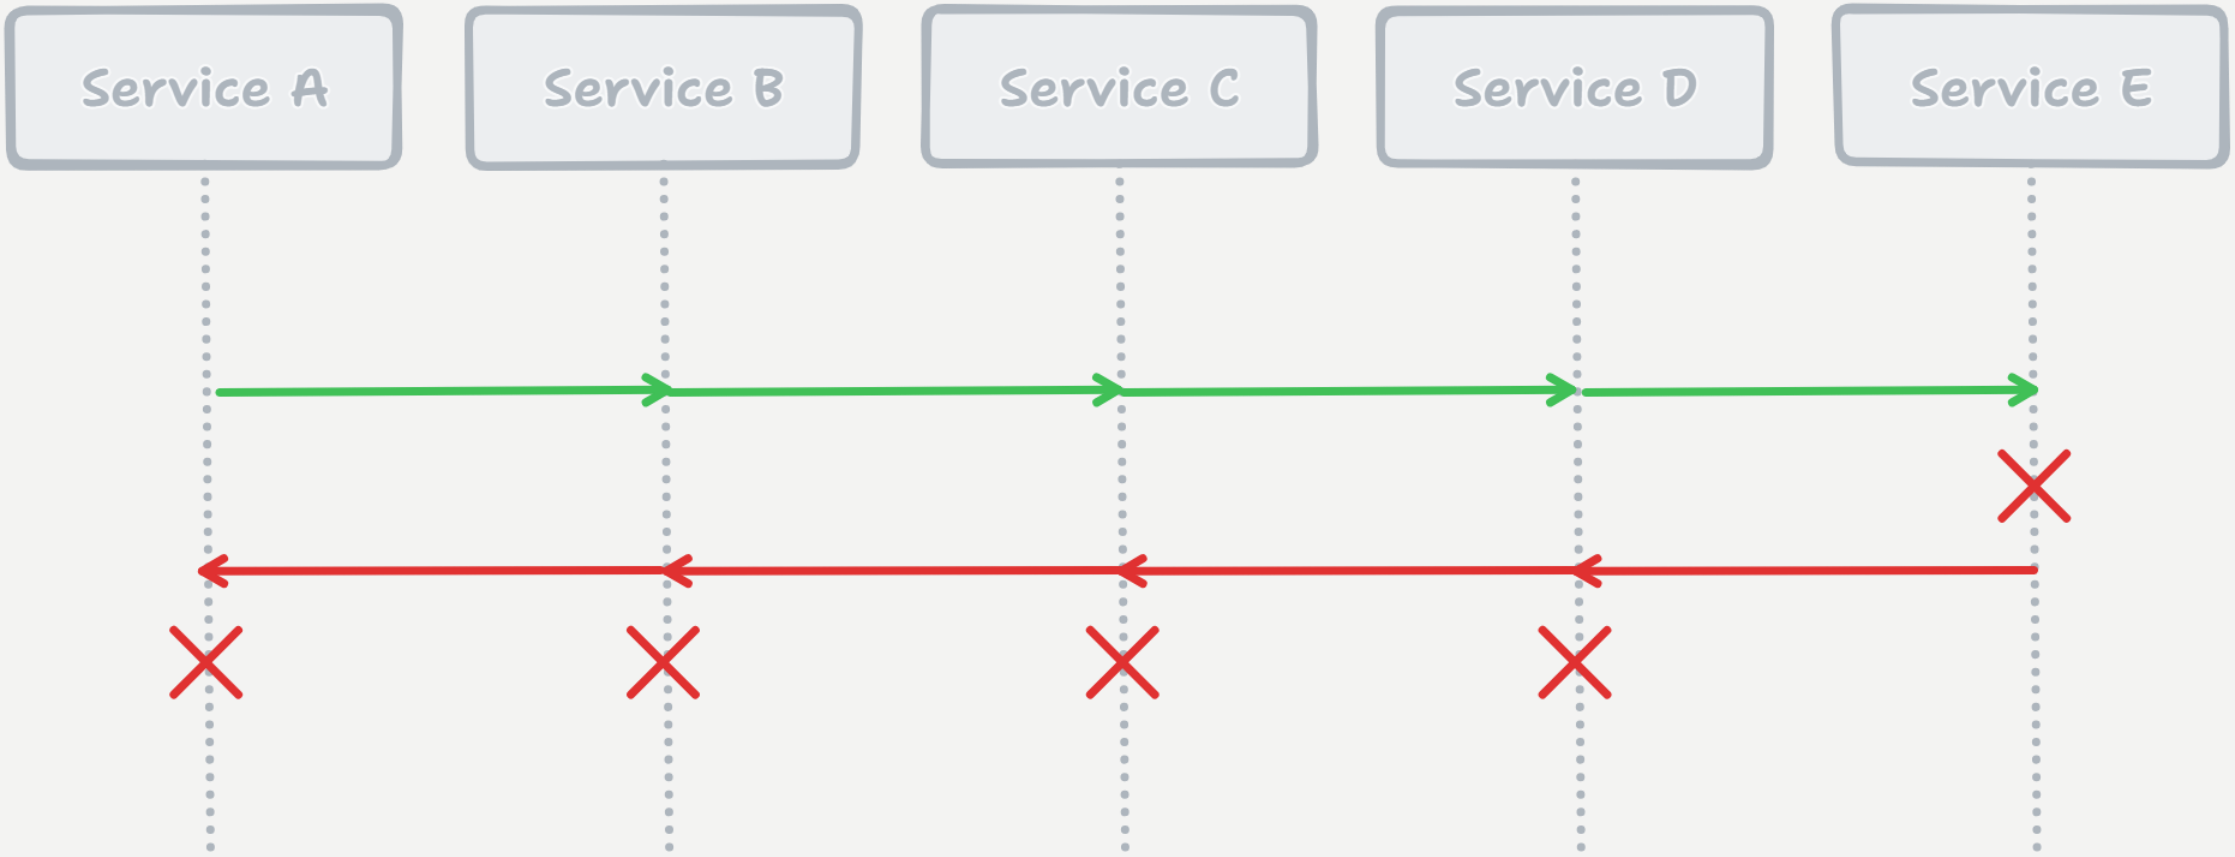

DISJONCTEUR

- Utilisation du Pattern **Circuit Breaker**
  - L'idée, c'est de fixer des règles pour lesquelles un service est « indisponible »
    - Temps de latence trop long
    - Nombre d'erreurs atteint
  - Si une des règles est détectée, mise en place d'une réponse alternative (**Fallback**)
    - Cette solution de repli doit être rapide et toujours disponible
    - Cette solution a une durée, c'est la durée pendant laquelle le circuit est « ouvert »

DISJONCTEUR

Solution alternative ici : un contenu par défaut par exemple

DISJONCTEUR

Le circuit est ouvert après la 6ème tentatives, ayant eu 3 tentatives infructueuses. Cet état sera actif pendant 5s avant de basculer en état "semi-ouvert", puis en état "fermé".

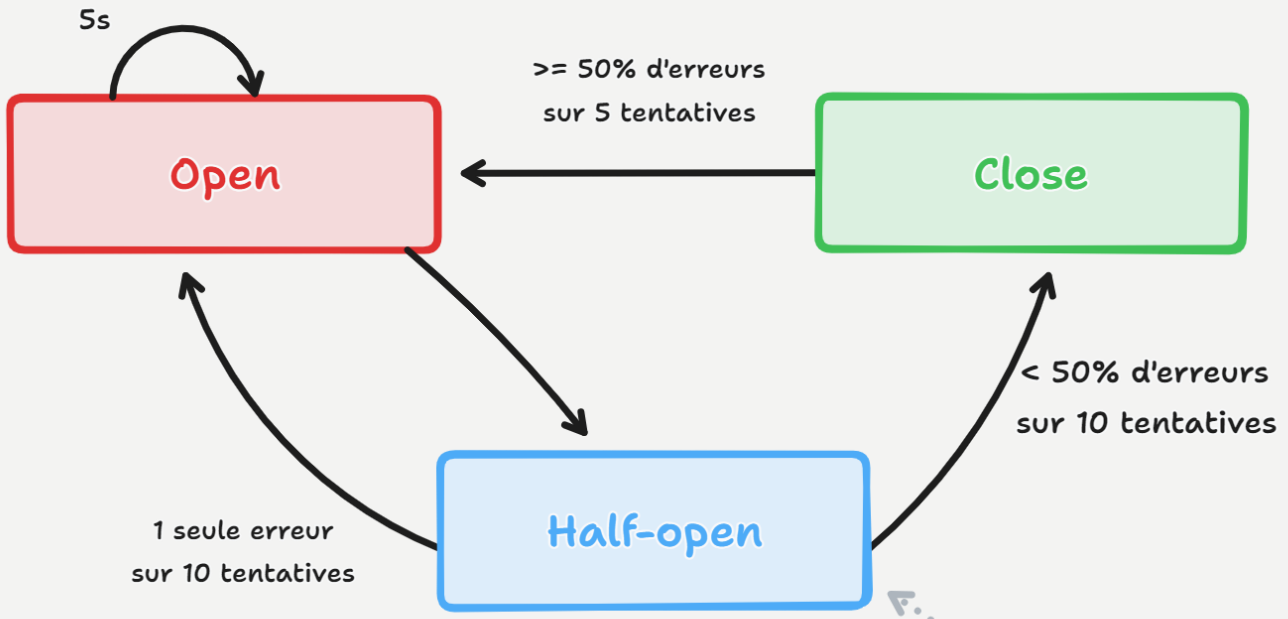

Les erreurs peuvent être des temps de latence > durée fixée, ou un statut HTTP 5xx ou 408

Dans cet état, les requêtes sont de nouveaux exécutées. Si une seule erreur est détectée, retour dans l'état "ouvert".

DISJONCTEUR

- En complément, il est possible d'utiliser le Pattern **Bulkhead**
  - Permet de limiter les accès concurrentiels au service
- Les deux sont complémentaires
  - **Circuit Breaker** permet de contourner un problème (implémenté côté appelant)
  - **Bulkhead** permet de limiter les appels simultanés pour alléger la charger (implémenté côté appelé)

- Lorsque le Pattern **Bulkhead** est implémenté, un nombre d'appels simultanés trop important peut faire augmenter le taux d'échec, et le **Circuit Breaker** entrera plus rapidement en état « ouvert »

DISJONCTEUR

- Il y a deux façons d'implémenter le Pattern **Bulkhead**
  - `Semaphore`
    - On limite le nombre de requêtes simultanées vers le service, on rejette les requêtes si on dépasse le seuil
  - `FixedThreadPoolBulkhead`
    - On utilise un pool de `Thread` pour le service, ainsi qu'une file d'attente (`Queue`)
    - Si le pool de Threads et la liste d'attente sont pleins, on rejette les requêtes suivantes

DISJONCTEUR

- Utilisation d'une technologie existante …
  - **Hystrix** (**JAVA** Netflix)
  - **Resilience4j** (**JAVA**)
  - **Polly** (**DOTNET**)
  - …

DISJONCTEUR

- Mettre en place un coupe circuit sur les services concernés

SPRING BOOT

EXEMPLE D'IMPLÉMENTATIONS

SPRING BOOT – CIRCUIT BREAKER

- Ajouter la dépendance *spring-cloud-starter-circuitbreaker-resilicence4j*

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-circuitbreaker-resilience4j</artifactId>
</dependency>
```

SPRING BOOT – CIRCUIT BREAKER

- Utiliser cette `Factory` pour paramétrer un **Fallback**

```
String result = this.circuitBreakerFactory.create("nomService").run(
  () ->  restTemplate.getForObject("...", String.class),
  t -> "défaut"
);
```

SPRING BOOT – CIRCUIT BREAKER

- Injecter `CircuitBreakerFactory` à l'endroit nécessaire
- Utiliser cette `Factory` pour paramétrer un **Fallback**
  - Exemple avec `RestTemplate`

```
String result = this.circuitBreakerFactory.create("nomService").run(
  () -> this.restTemplate.getForObject("...", String.class),
  t -> "défaut"
);
```

  - Exemple avec **OpenFeign**

```
String result = this.circuitBreakerFactory.create("nomService").run(
  () ->  this.serviceClient.getForObject("...", String.class),
  t -> "défaut"
);
```

SPRING BOOT – CIRCUIT BREAKER

- Dans le cas où **OpenFeign** est utilisé, il est possible de créer une classe de `Fallback`

```
@FeignClient(value = "nom-service", fallback = ServiceClient.Fallback.class)
public interface ServiceClient {
    @GetMapping("/api/endpoint/by-produit-id/{produitId}")
    public List<String> uneRequete(@PathVariable String produitId);

    @Component
    public static class Fallback implements ServiceClient {
        @Override
        public List<String> uneRequete(String produitId) {
            return List.of("valeur par défaut");
        }
    }
}
```

- Puis, dans la configuration

```
spring.cloud.openfeign.circuitbreaker.enabled = true
spring.cloud.openfeign.circuitbreaker.alphanumeric-ids.enabled = true
```

SPRING BOOT – CIRCUIT BREAKER

- Adapter les paramètres par défaut dans la configuration

```
resilience4j.circuitbreaker.instances.nomService.failure-rate-threshold = 50
resilience4j.circuitbreaker.instances.nomService.minimum-number-of-calls = 3
resilience4j.circuitbreaker.instances.nomService.permitted-number-of-calls-in-half-open-state = 10
resilience4j.circuitbreaker.instances.nomService.wait-duration-in-open-state = 5s
resilience4j.circuitbreaker.instances.nomService.sliding-window-size = 5
resilience4j.circuitbreaker.instances.nomService.sliding-window-type = count-based
resilience4j.circuitbreaker.instances.nomService.slow-call-duration-threshold = 1s
resilience4j.circuitbreaker.instances.nomService.slow-call-rate-threshold = 50
```

- failure-rate-threshold — Seuil d'échecs, en %
- minimum-number-of-calls — Nombre d'appels minimum
- permitted-number-of-calls-in-half-open-state — Nombre d'appels en état semi-ouvert
- wait-duration-in-open-state — Durée d'attente en état ouvert
- sliding-window-size — Nombre d'enregistrements ou durée en état fermé
- sliding-window-type — Type (nombre ou temps)
- slow-call-duration-threshold — Seuil de temps de réponse
- slow-call-rate-threshold — Seuil au-delà duquel un temps est lent, en %

SPRING BOOT – BULKHEAD

- Ajouter la dépendance *resilience4j-spring-boot3*

```
<dependency>
  <groupId>io.github.resilience4j</groupId>
  <artifactId>resilience4j-spring-boot3</artifactId>
</dependency>
```

SPRING BOOT – BULKHEAD

- Utiliser cette @Bulkhead et paramétrer un **Fallback**

```
@ResponseStatus(HttpStatus.TOO_MANY_REQUESTS)
public List<ProduitResponse> bulkheadFallback(BulkheadFullException e) {
  return new ArrayList<>();
}

@GetMapping
@Bulkhead(name = "produitsService", fallbackMethod = "bulkheadFallback")
public List<ProduitResponse> findAll() {
  // ...
}
```

SPRING BOOT – BULKHEAD

- Configurer **Bulkhead**

```
resilience4j.bulkhead.instances.produitsService.max-wait-duration = 1
resilience4j.bulkhead.instances.produitsService.max-concurrent-calls = 10
```

```
resilience4j.thread-pool-bulkhead.instances.produitsService.max-thread-pool-size = 10
resilience4j.thread-pool-bulkhead.instances.produitsService.core-thread-pool-size = 10
resilience4j.thread-pool-bulkhead.instances.produitsService.queue-capacity = 5
```

- max-wait-duration — Durée d'attente maximum
- max-concurrent-calls — Nombre d'appels simultanés autorisés

- max-thread-pool-size — Taille du pool de thread maximum
- core-thread-pool-size — Taille du pool de thread principal
- queue-capacity — Taille de la queue maximum

.NET6

EXEMPLE D'IMPLÉMENTATIONS

.NET6

- Ajouter le package *Microsoft.Extensions.Http.Polly*

```
<PackageReference Include="Microsoft.Extensions.Http.Polly" Version="6.0.10" />
```

.NET6

- Utiliser `HttpClientFactory` & `HttpClient`

```
builder.Services.AddHttpClient("nom-service", client => {
    client.BaseAddress = new Uri("lb://nom-service/");
})
.AddRandomLoadBalancer()
.AddTransientHttpErrorPolicy(policy => policy.CircuitBreakerAsync(3, TimeSpan.FromSeconds(5)));
```

```
var httpClient = _httpClientFactory.CreateClient("nom-service");

var fallbackForAnyException = Policy<string>
  .Handle<Exception>()
  .FallbackAsync(async (ct) => "défaut");

return await fallbackForAnyException.ExecuteAsync(async () => {
  return await httpClient.GetStringAsync("...");
});
```